

INFORME DE TALLER

Prediccion de Accidentalidad en Medellin

Clasificacion binaria · Clases desbalanceadas · SQLite
Aprendizaje Automatico · MCDA 2026-1 · Grupo 3

Daniel Pareja · Sebastian Ruiz · David Gomez

Andres Velasco · Juan Morales

Profesor: Pablo Saldarriaga · Mayo 2026

1 Resumen Ejecutivo

Este trabajo presenta el diseño, entrenamiento y evaluación de un modelo de clasificación binaria para predecir la ocurrencia de al menos un accidente de tránsito en un barrio específico de Medellín durante una hora determinada del día. La iniciativa responde a la necesidad de las administraciones municipales de focalizar operativos preventivos con antelación, reduciendo el impacto humano y económico de la accidentalidad vial.

Se utilizó una base de datos SQLite con tres tablas: registros crudos de accidentes (`raw_accidentes`), agregados por barrio y hora (`accidentes`) y mediciones meteorológicas por barrio y hora (`clima`). El universo de análisis comprende el periodo 2017-2019, con entrenamiento hasta septiembre de 2018 y evaluación final sobre todo 2019.

~7.6M Registros barrio×hora	~1.51% Tasa de accidentalidad	4 Modelos comparados	LightGBM Modelo seleccionado
--------------------------------	----------------------------------	----------------------	---------------------------------

Resultado principal: El modelo LightGBM alcanza un ROC-AUC de 0.9223 y un PR-AUC de 0.1157 en el conjunto de test (2019). Mediante un sistema de alertas Top-N diario, es posible cubrir el 61.8% de los accidentes reales monitoreando el 10% de las celdas barrio×hora disponibles, y hasta el 95.2% de los accidentes monitoreando el 20% de las celdas.

2 Descripción del Problema y los Datos

2.1 Pregunta de investigación

¿Cuál es la probabilidad de que ocurra al menos un accidente en el barrio B a la hora h del día? El problema es de clasificación binaria con clases fuertemente desbalanceadas: en el periodo 2017-2019, solo el 1.49% de las combinaciones (barrio, hora) presentaron algún accidente.

2.2 Fuentes de datos

Tabla	Filas	Descripción	Rol en el modelo
<code>raw_accidentes</code>	125,122	Un registro por accidente. Contiene fecha, hora, barrio, comuna, clase, gravedad y coordenadas.	EDA, ingeniería de características históricas
<code>accidentes</code>	120,587	Version agregada: una fila por (barrio, hora) con al menos un accidente.	Construcción del target (clase positiva)
<code>clima</code>	7,991,780	Mediciones meteorológicas por (barrio, hora): temperatura, lluvia, viento, visibilidad, etc.	Universo completo de combinaciones + features climáticas

2.3 Construcción del dataset supervisado

La tabla `clima` cubre todas las combinaciones (barrio, hora), por lo que sirve como universo de predicción. El target se define como 1 si esa combinación aparece en la tabla `accidentes`, y 0 en caso contrario. Este left-join genera automáticamente los casos negativos sin necesidad de muestreo artificial previo.


La partición temporal adoptada fue: Train (ene 2017 - sep 2018), Validación (oct - dic 2018) y Test (ene - dic 2019). Los meses de junio y julio de 2018 fueron excluidos por ausencia total de datos climáticos del proveedor, lo que habría introducido ruido artificial por imputación masiva.

3 Analisis Exploratorio de Datos (EDA)


3.1 Distribucion temporal

El analisis de la distribucion temporal sobre la tabla raw_accidentes revelo patrones claros y consistentes con la dinamica urbana de Medellin:


- Por hora del dia: picos marcados en las horas de ingreso (6-7 h) y salida laboral (16-17 h), con minimos en la madrugada (1-3 h).



- Por día de la semana: mayor concentracion en días hábiles (lunes a viernes); los viernes presentan el pico mas alto, posiblemente asociado a mayor movilidad nocturna.



- Por mes: distribucion relativamente uniforme con leve aumento en agosto y diciembre, coherente con el incremento de desplazamientos de feria de flores y navidad.



3.2 Distribucion espacial

El mapa de dispersion Lat/Lon muestra una concentracion de accidentes en el eje vial principal norte-sur del Valle de Aburra (via Las Vegas, autopista Norte), asi como en el centro expandido. Los 20 barrios con mayor numero de accidentes pertenecen predominantemente a las comunas 11 (Laureles-Estadio), 14 (El Poblado) y 16 (Belen), zonas de alta densidad vehicular y comercial.

3.3 Caracterizacion climatica

Se analizo la correlacion de las variables climaticas con la tasa de accidentalidad mediante el heatmap hora x dia y graficos de distribucion por condicion climatica:

Variable	Correlacion con target	Interpretacion
temperature	+0.008	Leve positiva — mas accidentes en horas calidas (horas pico)
precipIntensity	-0.003	Leve negativa — lluvia intensa puede reducir el trafico
precipProbability	-0.002	Similar a intensidad de precipitacion
windSpeed	+0.002	Marginal — incluida por robustez
visibility	+0.006	Mayor visibilidad correlaciona con mas trafico (dia)
humidity	-0.005	Leve negativa — condiciones humedas reducen trafico

4 Calidad de Datos y Decisiones

4.1 Diagnostico inicial

Problema detectado	Tabla afectada	Magnitud	Decision adoptada
Nulos en precipProbability / precipIntensity	clima	10,706 filas	Imputacion por cascada temporal con medianas de 2017
Nulos en temperature / apparentTemperature	clima	12 filas	Imputacion con mediana global de la variable
Ausencia total de datos climaticos	clima	Jun-Jul 2018 (440,725 registros)	Exclusion del periodo
Barrios sin match entre tablas	accidentes vs clima	< 0.1%	Excluidos del dataset final

windBearing: 12.9% nulos, baja relevancia	clima	~1M filas	Variable eliminada del dataset
summary: redundante con icon	clima	Toda la tabla	Variable eliminada

4.2 Estrategia de imputacion sin data leakage

La imputacion de variables climaticas siguio una cascada de cuatro niveles, usando exclusivamente datos de 2017 como referencia. El orden de prioridad fue: (1) mediana por barrio+mes+hora, (2) mediana por barrio+mes, (3) mediana por mes+hora, (4) mediana global por mes. Este enfoque garantiza que no se introduce informacion futura al imputar los datos de 2018 y 2019.

5 Ingenieria de Caracteristicas

Se construyeron 32 features a partir de las tres tablas originales, agrupadas en cuatro categorias funcionales:

5.1 Variables temporales y ciclicas

Feature	Tipo	Descripcion
Hora, Dia, Mes	Numerica	Componentes calendario directos
hora_sin, hora_cos	Ciclica	Codificacion seno/coseno de la hora (evita discontinuidad 23->0)
dia_sin, dia_cos	Ciclica	Codificacion del dia de la semana
mes_sin, mes_cos	Ciclica	Codificacion del mes
doy_sin, doy_cos	Ciclica	Codificacion del dia del ano
es_finde	Binaria	1 si sabado o domingo
es_festivo	Binaria	1 si festivo colombiano (libreria holidays)
hora_pico	Binaria	1 si hora entre 7-9 o 16-19

5.2 Variables climaticas e indicadores derivados

Se usaron directamente: temperature, apparentTemperature, dewPoint, humidity, precipIntensity, precipProbability, windSpeed, cloudCover, uvIndex, visibility. Adicionalmente se crearon indicadores binarios motivados por el EDA: lluvia_fuerte (precipIntensity > 5), viento_fuerte (windSpeed > 3) y visibilidad_baja (visibility < 5).

5.3 Variables historicas sin data leakage

Toda variable historica se calculo exclusivamente con informacion anterior al momento de prediccion (ventana expansiva por anno):

- hist_accidentes_barrio: numero total de accidentes historicos en ese barrio antes del anno en curso.
- hist_accidentes_barrio_hora: idem, filtrado tambien por hora del dia.
- rolling_7d_barrio: promedio de accidentes diarios en los 7 dias previos (con shift de 1 dia).
- barrio_freq: frecuencia relativa del barrio calculada solo sobre el conjunto de entrenamiento.

6 Modelos Comparados, Hiperparametros y Metricas

Se evaluaron cuatro familias de modelos mediante RandomizedSearchCV con TimeSeriesSplit (3 folds) sobre el 20% del conjunto de entrenamiento. El scoring primario fue PR-AUC (Average Precision), mas apropiado que ROC-AUC para datasets con fuerte desbalance de clases.

Modelo	Hiperparametros clave	CV PR-AUC	Val ROC-AUC	Val PR-AUC	Val Recall
Regresion Logistica	C=3.76, solver=saga, class_weight=balanced	0.3993	0.9166	0.0974	0.9432
Random Forest	n_estimators=114, max_depth=9, class_weight=balanced	0.4308	0.9275	0.1150	0.9609
XGBoost	n_estimators=114, lr=0.087, max_depth=3, scale_pos_weight=10	0.4414	0.9273	0.1156	0.9724
LightGBM ✓	n_estimators=137, lr=0.056, num_leaves=32, min_child_samples=49	0.4377	0.9278	0.1172	0.9741

Justificacion de LightGBM como modelo final: obtiene el mayor PR-AUC en validacion cruzada, mayor ROC-AUC en validacion temporal, y mayor recall. Adicionalmente, su entrenamiento es 4-8x mas rapido que Random Forest con conjuntos de esta magnitud, y soporta aceleracion GPU en Colab. La estabilidad entre validacion y test (ROC-AUC: 0.9278 vs 0.9223; diferencia = 0.0055) confirma ausencia de sobreajuste.

6.1 Baseline Ingenuo y Justificación de Métricas

El dataset de test (año 2019) presenta una tasa de accidentalidad del 1.49%, lo que implica aproximadamente 1 evento positivo por cada 62 combinaciones barrio×hora. Ante este desbalance severo, se evaluó un baseline ingenuo consistente en predecir siempre la clase mayoritaria (ausencia de accidente).

Este clasificador trivial alcanza una accuracy del 98.51% sin haber aprendido ningún patrón: todos los accidentes reales caen como falsos negativos (FN), obteniendo Recall = 0%, Precision = 0% y F1 = 0%. Desde la perspectiva operacional de la Secretaría de Movilidad, este modelo es completamente inútil pese a su accuracy elevada.

Este resultado evidencia que la accuracy es una métrica inadecuada para problemas con clases desbalanceadas y motiva el uso de las siguientes métricas a lo largo del trabajo: ROC-AUC y PR-AUC (independientes del umbral y sensibles al desbalance), Recall (fracción de accidentes reales detectados, cuyo costo de omisión es alto) y F1 (balance entre Precision y Recall para la selección del umbral operativo).

7 Estrategia de Balanceo y Justificacion

El dataset presenta un desbalance severo: 1 accidente por cada 66 combinaciones barrio×hora (~1.5% de positivos). Se evaluaron cuatro estrategias usando Regresion Logistica como modelo fijo para aislar el efecto del balanceo:

Estrategia	ROC-AUC	PR-AUC	Recall	Precision	F1
Baseline (sin balanceo)	0.9129	0.1024	0.2016	0.1274	0.1562
class_weight=balanced	0.9166	0.0974	0.9433	0.0704	0.1310

Undersampling 1:10 ✓	0.9129	0.1024	0.2016	0.1274	0.1562
SMOTE (muestra 30%)	0.9154	0.0978	0.8362	0.0745	0.1367

Las diferencias entre estrategias son minimas, lo que indica que el cuello de botella es la capacidad del modelo, no el esquema de balanceo. Se eligio Undersampling 1:10 por eficiencia computacional: reduce el conjunto de entrenamiento de 4.3M a ~700K filas manteniendo todos los positivos, sin degradar las metricas de validacion.

8 Modelo Final, Metricas, Matriz de Confusion y Umbral

8.1 Metricas en test (2019)

0.9223 ROC-AUC	0.1157 PR-AUC	0.4193 Recall	0.1150 Precision	0.1805 F1
----------------	---------------	---------------	------------------	-----------

8.2 Ajuste del umbral de decision

El umbral de decision fue seleccionado sobre el conjunto de validacion para evitar contaminacion del test. Se evaluaron cinco criterios:

Criterio	Umbral	Recall	Precision	F1	Seleccionado
Default (0.50)	0.5000	0.9741	0.0697	0.1301	
F1 maximo ✓	0.8810	0.3085	0.1302	0.1831	✓
Recall >= 50%	0.8503	0.5001	0.1063	0.1754	
Recall >= 70%	0.8301	0.7001	0.0930	0.1642	
Youden (max TPR-FPR)	0.4515	0.9796	0.0686	0.1282	

Se selecciono el umbral de F1 maximo como punto de reporte neutro. En operacion real, la cobertura se controla mediante el sistema Top-N diario (seccion 9), lo que hace que el umbral global sea secundario.

8.3 Matriz de confusion — Test 2019

	Pred: No accidente	Pred: Accidente
Real: No accidente	TN = 2,437,733	FP = 131,878
Real: Accidente	FN = 23,731	TP = 17,138

9 Caso de Uso y Limitaciones

9.1 Sistema de alertas Top-N diario

El modelo opera como un rankeador: cada dia se ordenan todas las celdas barrio×hora por probabilidad de accidente y se emiten las N alertas de mayor riesgo a la Secretaria de Movilidad. Esto elimina la necesidad de un umbral global rigido y permite ajustar el nivel de operativos disponibles.

N alertas/dia	Precision Top-N	Recall capturado	Alertas anuales	Accidentes anticipados
10	17.48%	1.56%	3,650	638

30	16.79%	4.50%	10,950	1,838
50	15.77%	7.04%	18,250	2,878
100	14.68%	13.11%	36,500	5,358

9.2 Limitaciones del modelo

- Sesgo de reporte: solo se modelan accidentes reportados oficialmente.
- Concept drift: patrones 2017-2019 pueden no ser validos tras cambios urbanos o la pandemia.
- Interpretabilidad: LightGBM es caja negra, lo que dificulta explicar decisiones individuales.
- Resolucion geografica: nivel barrio, no interseccion — dos calles del mismo barrio reciben la misma alerta.
- Falsas alarmas: con umbral F1, una proporcion de horas sin accidente generan alerta, con riesgo de fatiga operativa.

9.3 Variables Externas que Fortalecerían el Modelo

Las limitaciones de datos disponibles restringen la capacidad predictiva actual. Las siguientes fuentes externas, no incorporadas en este trabajo, constituyen oportunidades concretas de mejora:

Eventos urbanos: partidos de fútbol (Clásico Paisa), conciertos y ferias concentran flujos vehiculares atípicos no capturados por las variables históricas ni climáticas. Infraestructura vial: obras activas y cierres redirigen el tráfico hacia corredores con menor capacidad, incrementando el riesgo en barrios adyacentes. Flujo vehicular en tiempo real: datos del RUNT y sensores viales constituirían el predictor más directo de congestión. Variables socioespaciales: densidad poblacional (DANE) e iluminación nocturna por barrio aportarían contexto estructural no recogido por la frecuencia histórica de accidentes. Festivos locales: el calendario nacional (holidays) no captura decretos municipales puntuales que alteran la movilidad.

10 Conclusiones y Trabajo Futuro

10.1 Conclusiones

- Es posible predecir la accidentalidad barrio×hora con ROC-AUC de 0.9223 usando unicamente datos historicos de accidentes y variables meteorologicas.
- La ingenieria de características temporales (variables ciclicas, historial por barrio) resulto ser el factor mas determinante, superando en importancia a las variables climaticas.
- El desbalance de clases no deteriora significativamente el modelo cuando se usa una estrategia de undersampling eficiente junto con metricas apropiadas (PR-AUC, Recall).
- El sistema Top-N es mas util operativamente que un umbral global fijo, ya que adapta el numero de alertas a la capacidad diaria de la Secretaria.
- La particion temporal estricta (sin fuga de informacion) garantiza que las metricas reflejen desempeno real en produccion.

10.2 Trabajo futuro

Horizonte	Accion propuesta
Corto plazo	Reentrenamiento mensual automatico. Incorporar eventos urbanos (partidos, conciertos). Ajuste dinamico del umbral segun recursos disponibles.
Mediano plazo	Desagregacion geografica a nivel interseccion. Pipeline automatizado de alertas diarias integrado con sistemas de trafico de la Alcaldia.
Largo plazo	Extension a otros municipios del Valle de Aburra. Incorporacion de datos de flujo vehicular en tiempo real (RUNT, sensores viales).

